

Tecmilenio

Máster en Inteligencia Artificial Aplicada

Actividad 8

Monitorización de Modelos de Machine Learning (MLOps)

Alumno: Erika Cazarez

Profesor: _____ Ariel Vazquez Piña _____ Fecha: 19 Julio 2026

1. Objetivo

Implementar un sistema básico de monitorización para un modelo de Machine Learning mediante herramientas de MLOps, utilizando FastAPI y Streamlit para supervisar el comportamiento del modelo en tiempo real. El sistema registra automáticamente las predicciones, mide la latencia del servicio, genera alertas operativas y almacena los resultados en un archivo de monitoreo, facilitando la detección temprana de incidentes y el seguimiento del desempeño del modelo.

Introducción

En los proyectos de Machine Learning no basta con entrenar un modelo; también es necesario supervisar su comportamiento una vez desplegado. El monitoreo permite conocer el desempeño del modelo, registrar métricas operativas, detectar posibles fallas y responder oportunamente ante incidentes.

En esta actividad se desarrolló una solución de monitorización utilizando FastAPI como servicio de predicción y Streamlit como dashboard interactivo. Además, se implementó el registro automático de predicciones, métricas de latencia, alertas operativas y runbooks de respuesta a incidentes, siguiendo principios básicos de MLOps.

RUNBOOKS DE RESPUESTA A INCIDENTES

Runbook 1. Error de validación de entrada (HTTP 422)

Objetivo

Restablecer el servicio cuando la API rechaza una solicitud debido a un formato incorrecto de los datos de entrada.

Condición de activación

- Código HTTP 422.
- Mensaje:
Input should be a valid integer.

Evidencia

Durante las pruebas de la API se envió el campo Type con un valor tipo cadena ("H"), mientras que el modelo esperaba un valor entero. FastAPI rechazó correctamente la solicitud.

Procedimiento

Paso 1. Identificar el código de error recibido por la API.

Paso 2. Revisar el mensaje devuelto por FastAPI.

Paso 3. Confirmar cuál campo generó el error.

Paso 4. Comparar la solicitud enviada contra el esquema DatosEntrada.

Paso 5. Corregir el tipo de dato.

Paso 6. Reenviar la solicitud.

Paso 7. Verificar respuesta HTTP 200.

Paso 8. Confirmar generación de predicción.

Paso 9. Confirmar registro en monitoring_logs.csv.

Paso 10. Confirmar actualización del Dashboard.

Resultado esperado

La API procesa correctamente la solicitud y el incidente queda resuelto.

Runbook 2. Predicción de riesgo de falla

Objetivo

Responder oportunamente cuando el modelo detecta una condición de riesgo.

Condición de activación

- Probabilidad de falla superior al umbral (0.30).
- Predicción = 1.

Evidencia

Durante las pruebas se obtuvo:

- Probabilidad = **0.9652**
- Predicción = **1**
- Resultado = **"Riesgo de falla"**

El incidente quedó registrado automáticamente en el dashboard y en monitoring_logs.csv.

Procedimiento

Paso 1. Detectar la alerta generada por el modelo.

Paso 2. Verificar la probabilidad de falla.

Paso 3. Comparar contra el umbral configurado.

Paso 4. Confirmar que la predicción corresponde a "Riesgo de falla".

Paso 5. Registrar el evento en el archivo de monitoreo.

Paso 6. Verificar actualización del dashboard.

Paso 7. Revisar las variables de entrada asociadas a la predicción.

Paso 8. Notificar al responsable del proceso.

Paso 9. Recomendar inspección preventiva del equipo.

Paso 10. Continuar monitoreando nuevas predicciones.

Resultado esperado

El riesgo queda identificado oportunamente y se genera evidencia para apoyar la toma de decisiones antes de que ocurra una falla.

Estrategia de detección de Data Drift

Objetivo

Detectar cambios en la distribución de los datos de entrada que puedan afectar el desempeño del modelo de Machine Learning y reducir la precisión de las predicciones.

Estrategia implementada

El sistema registra automáticamente todas las predicciones realizadas mediante la API FastAPI en el archivo **monitoring_logs.csv**, incluyendo las variables de entrada utilizadas por el modelo.

Las variables monitoreadas son:

- Tipo de máquina (Type)
- Temperatura del aire
- Temperatura del proceso
- Velocidad de rotación
- Torque
- Desgaste de herramienta

Estos registros permiten comparar periódicamente los datos actuales contra los utilizados durante el entrenamiento del modelo para identificar posibles desviaciones.

Acciones cuando se detecte Data Drift

- Analizar la distribución de las variables de entrada.
- Comparar los nuevos datos con el conjunto de entrenamiento.
- Validar si disminuye la precisión del modelo.
- Reentrenar el modelo utilizando datos recientes.
- Publicar una nueva versión del modelo una vez validada.

Documentación de respuesta automatizada

Durante la operación del sistema, la API ejecuta automáticamente las siguientes acciones:

- Validación del formato de los datos de entrada mediante Pydantic.
- Generación de la predicción utilizando el modelo entrenado con XGBoost.
- Cálculo de la probabilidad de falla.
- Comparación con el umbral configurado.
- Registro automático de todas las predicciones en el archivo `monitoring_logs.csv`.
- Actualización del dashboard desarrollado en Streamlit.
- Registro de la latencia de cada predicción.

Cuando se detecta un dato inválido, la API responde automáticamente con el código **HTTP 422**, evitando que información incorrecta llegue al modelo.

10. Configuración de Alertas

Las alertas fueron configuradas utilizando un umbral de decisión de **0.30**.


Condición	Acción
Probabilidad < 0.30	Sin falla esperada
Probabilidad ≥ 0.30	Riesgo de falla

Las alertas son visibles tanto en la respuesta de FastAPI como en el Dashboard de Streamlit, permitiendo identificar rápidamente condiciones críticas.

11. Evidencia de Implementación

Dashboard de monitoreo

Figura 1. Dashboard de monitoreo desarrollado en Streamlit.



API FastAPI

Figura 2. Prueba de predicción utilizando Swagger UI.

Request body required

Edit Value | Schema

```
{
  "Type": "H",
  "Air_temperature_K": 305.2,
  "Process_temperature_K": 315.3,
  "Rotational_speed_rpm": 1095,
  "Torque_Nm": 74.5,
  "Tool_wear_min": 240
}
```

Execute

12.-Simulación de Incidentes

Incidente 1. Error de validación (HTTP 422)

Durante las pruebas se envió el campo **Type** con un valor tipo cadena ("H"), mientras que la API esperaba un valor entero.

El sistema respondió correctamente con el código **HTTP 422 (Unprocessable Content)**, impidiendo que datos inválidos fueran procesados por el modelo.

Resultado obtenido

- Validación correcta de la entrada.
- Protección del modelo.
- Prevención de registros incorrectos.

Evidencia

Responses

Curl

```
curl -X 'POST' \
  'http://127.0.0.1:8000/predict' \
  -H 'accept: application/json' \
  -H 'Content-Type: application/json' \
  -d '{
    "type": "H",
    "Air_temperature_K": 305.2,
    "Process_temperature_K": 315.3,
    "Rotational_speed_rpm": 1095,
    "Torque_Nm": 74.5,
    "Tool_wear_min": 240
  }'
```

Request URL

http://127.0.0.1:8000/predict

Server response

Code

Details

422

Error: Unprocessable Content

Response body

```
{
  "detail": {
    "type": "int_parsing",
    "loc": [
      "body",
      "type"
    ],
    "msg": "Input should be a valid integer, unable to parse string as an integer",
    "input": "H"
  }
}
```

Response headers

```
content-length: 147
content-type: application/json
date: Mon, 20 Jul 2026 04:43:12 GMT
server: uvicorn
```

Responses

Code

Description

Registro automático de predicciones

Figura 3. Historial de predicciones almacenado automáticamente en monitoring_logs.csv.

Historico de predicciones

	timestamp	Type	Air_temperature_K	Process_temperature_K	Rotational_speed_rpm	Torque_Nm	Tool_wear_min	probabilidad_falla	umbral	prediccion	resultado	latencia_ms	estado
5	2026-07-19 22:10:26	6	304.9	315	1150	70.5	248	0.9652	0.3	1	Riesgo de falla	3.9837	OK
4	2026-07-19 22:09:24	5	306.8	316.5	1120	72	250	0.9652	0.3	1	Riesgo de falla	4.5971	OK
3	2026-07-19 21:36:10	2	298	309	2800	15	10	0.02	0.3	0	Sin falla esperada	3.5351	OK
2	2026-07-19 21:33:47	1	305	315	1200	65	220	0.9668	0.3	1	Riesgo de falla	3.4102	OK
1	2026-07-19 21:30:02	0	300	310	1500	40	50	0.0008	0.3	0	Sin falla esperada	3.7091	OK
0	2026-07-19 19:31:19	0	30	60	1200	0	0	0.2796	0.3	0	Sin falla esperada	29.7186	OK

Incidente 2. Riesgo de falla detectado

Se ejecutó una prueba utilizando datos correspondientes a una condición crítica de operación.

Resultado obtenido:

- Probabilidad de falla: **0.9652**
- Umbral: **0.30**

- Predicción: **1**
- Resultado: **Riesgo de falla**

La predicción fue registrada automáticamente en el archivo de monitoreo y visualizada en el dashboard.

Evidencia

13.- Resultados obtenidos

La solución implementada permitió desarrollar un sistema básico de monitoreo para un modelo de Machine Learning utilizando herramientas de MLOps.

Las principales funcionalidades implementadas fueron:

- API REST desarrollada con FastAPI.
- Modelo de predicción integrado mediante XGBoost.
- Registro automático de predicciones y métricas.
- Dashboard interactivo desarrollado con Streamlit.
- Monitoreo de latencia.
- Gestión de alertas mediante umbral configurable.
- Validación automática de entradas mediante Pydantic.
- Documentación de procedimientos (Runbooks) para la atención de incidentes.

Los resultados obtenidos demuestran que el sistema es capaz de monitorear el comportamiento del modelo, registrar evidencia operativa y facilitar la detección temprana de condiciones de riesgo, proporcionando una base para futuras mejoras como la detección automática de *Data Drift* y el reentrenamiento continuo del modelo.